

BeaconNova：基于多源数据融合的文旅场景舒适度评估与风险超前预警模型研究

BeaconNova Team

2026 年 9 月 13 日

摘要

面向八达岭长城景区在节假日、暑期和高峰时段面临的安检排队、游线承载、索道拥堵与天气体感波动问题，本文构建了 BeaconNova 文旅场景舒适度评估与风险超前预警模型。模型融合安检口 5 分钟客流、票务入园流水、轨道交通到达、核心点位承载能力、索道运力参数、导览图上下文、赛题文本信息以及 Open-Meteo 小时级历史天气数据，形成统一的时空运营样本。方法上，本文先建立表格基线和真实天气增强图卷积网络，再引入业务先验与历史时滞相关性校准的景区运营图，并进一步设计自适应邻接图卷积、门控膨胀 TCN-GCN 和验证集 Ridge 后校准机制。实验结果表明，优化版自适应 GCN 在 60 分钟客流预测上取得 MAE 2.5352，在 60 分钟等待时间预测上取得 MAE 0.4540；优化版 TCN-GCN 分别达到 2.5532 和 0.4553，均优于此前真实天气 GCN 版本。系统还输出蓝、黄、橙、红四级风险预警、风险主因解释和干预策略仿真结果，可为景区提前分流、通道调度、索道削峰和天气保障提供可执行依据。

关键词：文旅客流预测；舒适度评估；风险预警；图神经网络；时空预测；自适应邻接；TCN-GCN

1 引言

热门文旅景区的客流调度具有明显的时空耦合特征。游客到达通常受到票务预约、公共交通班次、节假日日历和天气体感的共同影响；入园后，安检口、索道平台、核心打卡点和窄路段之间又存在连续的拥堵传导。若仅依赖单点历史均值或人工经验进行预警，往往难以及时识别高峰前的累积压力，也难以解释风险由何处传来、应当采取何种干预措施。

北京数智创新大赛赛题五要求参赛方案围绕多源数据融合，完成文旅场景舒适度评估与风险超前预警。本文以八达岭长城景区为对象，构建 BeaconNova 模型体系。该体系的目标不是单纯预测一个客流数值，而是形成从数据接入、特征构建、时空图预测、风险评分、策略仿真到可视化展示的闭环。模型重点回答三个问题：第一，未来

30 分钟和 60 分钟各安检通道的客流与排队等待时间如何变化；第二，当前和未来风险由等待、客流、容量、索道、天气等哪一类因素主导；第三，若启动分流、增开通道或索道削峰，风险和舒适度将如何变化。

2 相关工作

交通与人流预测天然适合采用时空图建模。STGCN 将交通传感器组织为图结构，并通过时间卷积与图卷积联合学习空间依赖和时间变化，证明了全卷积时空结构在交通预测中的有效性 [1]。DCRNN 将交通流视为有向图上的扩散过程，并用编码器-解码器结构捕捉非线性时间动态 [2]。Graph WaveNet 指出固定图结构未必反映真实依赖，因此提出由节点嵌入学习自适应邻接矩阵，并用膨胀一维卷积扩大时间感受野 [3]。TCN 则系统展示了残差膨胀卷积在序列建模中的稳定性和长程依赖表达能力 [4]。

本文借鉴上述思路，但针对景区运营场景做了轻量化改造：一方面保留赛题资料、导览图和业务知识形成的显式拓扑，使模型具有解释性；另一方面引入历史时滞相关性和可学习自适应邻接，弥补手工边关系无法覆盖的隐含传播路径。天气数据采用 Open-Meteo Historical Weather API，该接口提供基于再分析和数值天气模型的小时级历史气象变量，可覆盖无景区微气象站的训练阶段 [5]。

3 数据与任务定义

3.1 数据来源

本文使用赛题文件夹中的五类原始数据和两类上下文资产。第一类为安检口 5 分钟安检数据，包含安检口、通道、通过人数、平均排队等待时间和包检量，是监督学习的核心数据。第二类为入园票务流水，按 5 分钟窗口聚合为票务入园量、近 30/60 分钟入园量、当日累计入园量和票种结构。第三类为轨道交通客流，作为游客到达的先行信号。第四类为核心打卡点承载与服务效率参数，提供瞬时容量、小时通行能力、停留时长、设施配置和瓶颈风险。第五类为南北索道基本情况，提供额定载客、发车间隔、饱和运力、平台容量和合理排队阈值。

除结构化表格外，本文还读取官方导览图、网友导览图和赛题说明文档，抽取静态上下文画像，形成地图节点和文档节点。真实天气由 Open-Meteo 接口按八达岭附近坐标 40.3597, 116.0201 拉取，覆盖 2025-07-01 至 2025-12-31，共 4416 条小时记录，字段包括气温、体感温度、湿度、降水、降雨标记、风速、阵风、天气代码、云量以及综合天气舒适惩罚。小时天气通过时间对齐并入 5 分钟运营样本。

3.2 预测与预警任务

设安检通道节点集合为 V_s ，时间粒度为 5 分钟。对任一通道 $i \in V_s$ 和时间 t ，模型预测未来 h 个时间步后的通过人数 $y_{i,t+h}^p$ 与平均等待时间 $y_{i,t+h}^w$ ，其中 $h \in \{6, 12\}$ ，

分别对应 30 分钟和 60 分钟。模型进一步基于预测值和多源压力因子计算舒适度分数 $C_{i,t,h} \in [0, 100]$ 与风险分数 $R_{i,t,h} \in [0, 1]$ ，并映射为蓝色、黄色、橙色、红色四级预警。

4 方法

4.1 特征工程

特征体系包含时间、日历、票务、安检通道历史、系统负载、轨道到达、容量约束、索道运力、天气体感和上下文画像。时间特征包括小时、星期、月份、5 分钟日内序号和正余弦周期编码；日历特征包括假期、调休工作日、暑期、距假期天数和假期序位；通道历史特征包括通过人数、等待时间、包检量的 1、2、3、6、12 个窗口滞后，以及 15、30、60 分钟滚动均值。容量与索道特征刻画点位瞬时压力、小时通行压力、瓶颈压力、索道平台压力和轨道到达对索道的冲击。天气特征进一步刻画高温、低温、大风和降雨对游客体感的影响。

4.2 景区运营图构建与边权校准

本文构建包含 24 个节点和 300 条有向边的景区运营图。节点类型包括 9 个安检通道、8 个核心点位或险要路段、2 个索道、2 个导览图上下文节点、1 个赛题说明文档节点、1 个票务全局节点和 1 个轨道交通全局节点。初始边关系由同安检口通道连接、票务/轨道全局信号连接、前山/外餐入口至南北游线连接、索道至平台和打卡点连接、核心点位沿游线顺序连接等构成。

为避免完全依赖人工拓扑，本文引入历史时滞相关性校准边权。对边 (u, v) ，在 0 至 60 分钟时滞范围内搜索最大相关性 ρ_{uv} ，并与业务先验权重 w_{uv}^0 融合：

$$w_{uv} = 0.65w_{uv}^0 + 0.35 \max(0, \rho_{uv}). \quad (1)$$

校准后的邻接矩阵再进行归一化，既保留景区业务可解释性，也使历史拥堵传导关系进入图卷积。

4.3 自适应 GCN

优化版 GCN 在校准邻接矩阵 A 的基础上加入可学习自适应邻接矩阵。给定节点嵌入 E_1, E_2 ，自适应邻接为

$$A_{adp} = \text{softmax}(\text{ReLU}(E_1 E_2)). \quad (2)$$

最终邻接矩阵为

$$\tilde{A} = (1 - \lambda)A + \lambda A_{adp}, \quad (3)$$

其中 $\lambda = 0.08$ 。模型使用两层残差图卷积、LayerNorm、Dropout 和多目标回归头，同时预测 30/60 分钟客流与等待时间。

4.4 门控膨胀 TCN-GCN

为显式建模过去 60 分钟的变化趋势，本文设计 TCN-GCN 时序图模型。输入为过去 12 个 5 分钟窗口的节点特征序列。时间模块采用门控膨胀残差卷积，膨胀率设置为 1、2、4；每个时间块先通过一维卷积产生门控分支和值分支，再计算

$$H = \tanh(H_v) \odot \sigma(H_g), \quad (4)$$

并通过残差连接和归一化稳定训练。时间表征由最后时刻与序列均值加权得到，随后进入自适应邻接 GCN。该结构兼顾近期状态和过去一小时趋势，对长城景区这种具有批量到达和延迟传播特征的场景更贴近实际。

4.5 验证集后校准

深度模型在低负载或突增负载样本上容易出现系统性偏差。本文在训练集内部留出最近 7 天作为验证集，仅在验证集上拟合 Ridge 线性后校准器。校准器输入包括模型原始预测、当前通道人数或等待时间、滞后特征、滚动均值、同安检口负载和系统负载，输出校准后的目标值。该步骤不使用测试集标签，因此不会造成测试集泄露。

4.6 舒适度与风险评分

舒适度评分综合等待压力、预测客流压力、包检压力、短时增长压力、容量压力、索道压力、暴露风险和天气压力。风险主因取各压力分项中的最大贡献项。风险等级采用固定业务阈值与预测分位阈值结合的混合规则，保证在高负载时具备绝对预警意义，在低负载时仍保留排序能力。

5 实验设置与结果

5.1 实验设置

样本按时间顺序切分，最近 21 天作为测试集，训练区间中最近 7 天作为验证集。图模型使用 19308 个时间样本、24 个节点、300 条有向边和 112 个节点特征。优化版 GCN 使用隐藏维度 128、Dropout 0.08、训练上限 24 轮、早停耐心 6；优化版 TCN-GCN 使用 12 步历史窗口、隐藏维度 128、学习率 0.0007、Dropout 0.08、训练上限 24 轮。训练设备为 CUDA。

5.2 预测精度

表1 给出主要版本在最近 21 天测试集上的 MAE 指标。可以看到，v0.5.0 真实天气 GCN 曾是预测精度最优版本；经过自适应邻接、门控膨胀 TCN 和验证集后校准后，两个图方法的 60 分钟客流与等待时间 MAE 均进一步下降。

表 1: 主要模型预测 MAE 对比

模型版本	30 分钟客流	30 分钟等待	60 分钟客流	60 分钟等待
v0.5 真实天气 GCN	2.6125	0.4693	2.6054	0.4619
原 v0.6 校准边权 GCN	2.6719	0.4842	2.7277	0.4896
优化版自适应 GCN	2.5884	0.4627	2.5352	0.4540
原 v0.7 TCN-GCN	2.6953	0.4841	2.7578	0.4939
优化版 TCN-GCN	2.6027	0.4639	2.5532	0.4553

表2 展示优化版模型的完整误差指标。优化版自适应 GCN 的 60 分钟客流 WAPE 为 0.2860, 等待时间 WAPE 为 0.3137; 优化版 TCN-GCN 的对应 WAPE 分别为 0.2886 和 0.3149。二者差距很小, 说明当前数据规模下, 后校准和自适应邻接对误差下降贡献显著, 时序模块仍有进一步调参空间。

表 2: 优化版模型完整测试指标

模型	目标	MAE	RMSE	WAPE
自适应 GCN	30 分钟客流	2.5884	3.1598	0.2923
自适应 GCN	30 分钟等待	0.4627	0.5617	0.3199
自适应 GCN	60 分钟客流	2.5352	3.0535	0.2860
自适应 GCN	60 分钟等待	0.4540	0.5487	0.3137
TCN-GCN	30 分钟客流	2.6027	3.1527	0.2939
TCN-GCN	30 分钟等待	0.4639	0.5602	0.3207
TCN-GCN	60 分钟客流	2.5532	3.0838	0.2886
TCN-GCN	60 分钟等待	0.4553	0.5501	0.3149

5.3 风险预警与策略仿真

在 60 分钟窗口下, 优化版预测结果经舒适度和风险评分后, 可输出节点级风险等级、风险主因和压力分项。进一步地, 策略仿真模块对黄色及以上风险样本触发分流引导策略, 共触发 4509 次; 平均风险分数下降 0.0602, 平均舒适度提升 6.02 分, 平均等待时间压降 0.21 分钟, 橙红预警样本从 1804 条降至 451 条, 减少 1353 条。该结果说明模型不仅能够完成预测评分, 也能向实际运营动作转化。

6 系统实现

BeaconNova 采用 Python 工程化实现，核心模块包括数据读取、特征工程、舒适度评分、图构建、边权校准、图模型训练、时序图模型训练、策略仿真、真实天气接口和本地看板。真实天气由 `scripts/fetch_weather.py` 拉取并写入 `weather.csv`；优化版 GCN 由 `scripts/run_graph_model.py` 运行；优化版 TCN-GCN 由 `scripts/run_temporal_graph_model.py` 运行；看板数据由 `scripts/build_dashboard_data.py` 汇总。

本地看板位于 `dashboard/index.html`。页面展示模型指标、导览图风险热区、60 分钟风险等级分布、真实天气体感、策略收益和历史传导高权重边。看板无需联网即可打开，适用于答辩演示和阶段性验收。

7 结论

本文完成了面向八达岭长城景区的 BeaconNova 多源融合舒适度评估与风险超前预警模型。相比早期表格基线，图模型显著降低预测误差；相比 v0.5.0 真实天气 GCN，优化版自适应 GCN 和优化版 TCN-GCN 又通过自适应邻接、门控膨胀时间卷积和验证集后校准进一步降低 60 分钟 MAE。更重要的是，系统形成了从预测到预警、从预警到策略仿真、从结果到看板展示的闭环，为景区精细化调度提供了可复现、可解释、可扩展的技术基础。

8 后续优化方向

后续工作可从以下方向继续推进。

第一，构建实时数据闭环。当前天气为历史小时数据，后续应接入实时天气预报、景区闸机实时流、索道排队监测、视频客流估计和设备状态，实现滚动预测与在线预警。

第二，升级动态图拓扑。当前自适应邻接为全局可学习矩阵，后续可引入节假日、时段、天气和突发事件条件，使边权随时间动态变化，并结合导览图距离、坡度、道路宽度和游客移动路径进行空间约束。

第三，优化策略仿真为约束决策。现阶段策略收益由规则化参数估计，后续应加入人力成本、通道开启成本、广播触达率、游客服从率、索道班次约束和安全容量红线，形成多目标优化或强化学习调度模型。

第四，增强极端场景鲁棒性。对于强降雨、大风、设备停运、团队游客集中到达等样本稀缺场景，可采用数据增强、异常检测、分位数预测和不确定性估计，使预警结果从点预测扩展为风险区间。

第五，完善评估体系。除 MAE、RMSE、WAPE 外，还应评估红橙预警召回率、提前量、误报率、舒适度改善幅度和策略成本收益比，使模型评价更贴近景区运营目标。

参考文献

- [1] Yu, B., Yin, H., and Zhu, Z. Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting. IJCAI, 2018. <https://www.ijcai.org/proceedings/2018/0505.pdf>
- [2] Li, Y., Yu, R., Shahabi, C., and Liu, Y. Diffusion Convolutional Recurrent Neural Network: Data-Driven Traffic Forecasting. ICLR, 2018. <https://openreview.net/forum?id=SJiHXGWAZ>
- [3] Wu, Z., Pan, S., Long, G., Jiang, J., and Zhang, C. Graph WaveNet for Deep Spatial-Temporal Graph Modeling. IJCAI, 2019. <https://www.ijcai.org/proceedings/2019/0264.pdf>
- [4] Bai, S., Kolter, J. Z., and Koltun, V. An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. arXiv:1803.01271, 2018. <https://arxiv.org/abs/1803.01271>
- [5] Open-Meteo. Historical Weather API Documentation. <https://open-meteo.com/en/docs/historical-weather-api>